

Progetto Database NoSQL: Sentiment Analysis dei commenti social su un brand tramite Elasticsearch

Introduzione

Il presente documento descrive il lavoro svolto per la progettazione, l'implementazione e la validazione di un sistema informativo NoSQL a supporto della *sentiment analysis* su un brand fittizio di prodotti tecnologici (*TechNova*). L'obiettivo del progetto è consentire il monitoraggio in tempo reale delle opinioni espresse dagli utenti sui principali canali social, l'individuazione tempestiva delle criticità reputazionali e l'estrazione di insight utili al management per orientare le decisioni operative.

A differenza di un sistema relazionale, dove i dati transazionali richiedono consistenza rigida e uno schema stabile, qui il dato di partenza è testo libero e destrutturato: i commenti degli utenti non seguono un formato prevedibile, contengono errori di battitura, linguaggio informale e variazioni lessicali. *Elasticsearch* è stato scelto come motore di recupero delle informazioni proprio per queste caratteristiche, offrendo ricerca full-text, tolleranza agli errori e aggregazioni in tempo reale su volumi di dati che crescono rapidamente.

1. Modello dei Dati

A differenza della modellazione relazionale, che nasce dalla scomposizione in entità distinte e relazioni normalizzate, la progettazione NoSQL è partita da un'unica domanda: quale documento risponde nel modo più efficiente alle interrogazioni analitiche richieste? La scelta è ricaduta su un singolo indice denormalizzato, denominato `commenti_social`, in cui ogni documento rappresenta un commento pubblicato su un social network.

Campo	Tipo	Descrizione
<code>id_commento</code>	keyword	Identificativo univoco del commento
<code>piattaforma</code>	keyword	Canale social di provenienza (twitter, instagram, facebook)
<code>id_post</code>	keyword	Riferimento al post/tweet originario a cui il commento appartiene
<code>utente_handle</code>	keyword	Identificativo dell'autore del commento sulla piattaforma
<code>brand_menzionato</code>	keyword	Brand monitorato, predisposto per un futuro scenario multi-brand
<code>sentiment</code>	keyword	Etichetta categorica: positivo, negativo, neutro
<code>punteggio_sentiment</code>	float	Score continuo del sentiment, da -1 a +1
<code>testo_commento</code>	text (it_analyzer)	Testo libero del commento, analizzato con stemming italiano
<code>hashtag</code>	keyword (array)	Elenco di hashtag associati, usato per aggregazioni per topic
<code>num_like</code>	integer	Numero di like/reazioni ricevute, proxy dell'engagement
<code>data_commento</code>	date	Data di pubblicazione del commento

Due scelte di modellazione meritano una nota di progettazione specifica, analoga a quella riservata agli attributi critici in un modello relazionale:

- `sentiment` e `punteggio_sentiment`: il `sentiment` non è dichiarato esplicitamente dall'utente, ma deve essere inferito da un classificatore. Per questo si mantengono sia un'etichetta categorica di sintesi (`sentiment`) sia uno score continuo (`punteggio_sentiment`), coerente con l'output tipico di un modello di sentiment analysis reale.
- `hashtag` come array di tipo `keyword`: a differenza di `testo_commento`, che deve supportare ricerca full-text con stemming, gli hashtag richiedono corrispondenza esatta per poter essere aggregati in un ranking di topic (terms aggregation); da qui la scelta di due tipi di campo differenti per due esigenze di interrogazione differenti.

2. Implementazione Elasticsearch

L'infrastruttura è stata sviluppata su un'istanza Elasticsearch (creazione_db_ES.txt), con creazione dell'indice tramite richiesta PUT comprensiva di mapping esplicito e di un analyzer personalizzato di tipo italian, che applica lo stemming nativo alla lingua italiana: una ricerca sul lemma "pulizia" intercetta così anche varianti come "pulito" o "pulitissima".

Il popolamento è stato realizzato dal LLM Claude manualmente, commento per commento, per un totale di 54 documenti (popolamento_ES.txt): ogni testo è stato scritto individualmente per garantire varietà lessicale autentica ed evitare pattern testuali riconoscibili, mantenendo al contempo una coerenza narrativa nel tempo.

Dimensione	Categoria	Volume
Sentiment	Negativo	25
Sentiment	Positivo	23
Sentiment	Neutro	6
Piattaforma	Twitter	22
Piattaforma	Instagram	16
Piattaforma	Facebook	16

Logiche di Analisi del Testo

Non essendoci, in un contesto NoSQL documentale, l'equivalente diretto dei trigger relazionali, le logiche di validazione e di analisi si concentrano sul motore di ricerca stesso:

- *Analyzer italiano* (it_analyzer): normalizza il testo libero riducendo ogni parola alla radice linguistica, azzerando l'impatto di flessioni e variazioni morfologiche sulla ricerca.
- *Fuzziness AUTO*: applicata nelle query di ricerca testuale, tollera errori di battitura e piccole variazioni ortografiche tipiche del linguaggio informale dei social network.
- *Multi-match su più campi e più termini*: consente di isolare commenti che menzionano un insieme di sinonimi (es. "prezzo", "costo", "caro") senza dover moltiplicare le query per ogni singola parola chiave.

3. Query di Analisi

Nel corso dello sviluppo sono stati individuati sei temi di interesse per un ente commissionante (query_interrogazioni_ES.txt), pensati per coprire in modo esaustivo gli scenari gestionali tipici del social listening: reputazione generale del brand, gestione delle crisi, individuazione dei pain point ricorrenti, confronto tra canali e identificazione degli utenti più influenti.

Questi sei temi sono stati selezionati e integrati nello strato applicativo Python (interazione_ES_python.py), per dimostrare l'intero flusso di interazione.

I temi indagati sono:

- 1) Reputazione generale nel tempo: aggrega volume e sentiment medio mese per mese, per individuare se la percezione del brand sta migliorando o peggiorando.
- 2) Gestione delle crisi reputazionali: isola i commenti con sentiment fortemente negativo combinato ad alto engagement, i soli realmente rilevanti ai fini di un intervento di crisis management.
- 3) Pain point ricorrenti per topic: produce un ranking degli argomenti (hashtag) più associati a sentiment negativo, utile per allocare le priorità di intervento tra i reparti aziendali.
- 4) Confronto tra piattaforme: mette a confronto sentiment medio, distribuzione ed engagement medio sui tre canali monitorati, per orientare gli investimenti in comunicazione.
- 5) Efficacia delle iniziative aziendali: confronta il sentiment sul tema degli aggiornamenti software prima e dopo una data di rilascio, e misura separatamente la ricezione delle promozioni commerciali.
- 6) Utenti più impattanti: individua gli account con maggiore engagement totale, distinguendo promotori e detrattori in base al segno del sentiment medio espresso.

4. Conclusione

Il progetto ha portato alla realizzazione di un sistema di social listening completo, dalla progettazione del documento fino alla validazione del popolamento e alla predisposizione di un set esaustivo di interrogazioni analitiche.

Il sistema è stato validato sia nella struttura del mapping, sia nel comportamento delle interrogazioni. Ne risulta una base informativa pronta per essere collegata a una pipeline reale, con naturali sviluppi futuri nell'integrazione di un modello di sentiment analysis automatico in sostituzione dell'etichettatura manuale, e nell'estensione a uno scenario multi-brand.